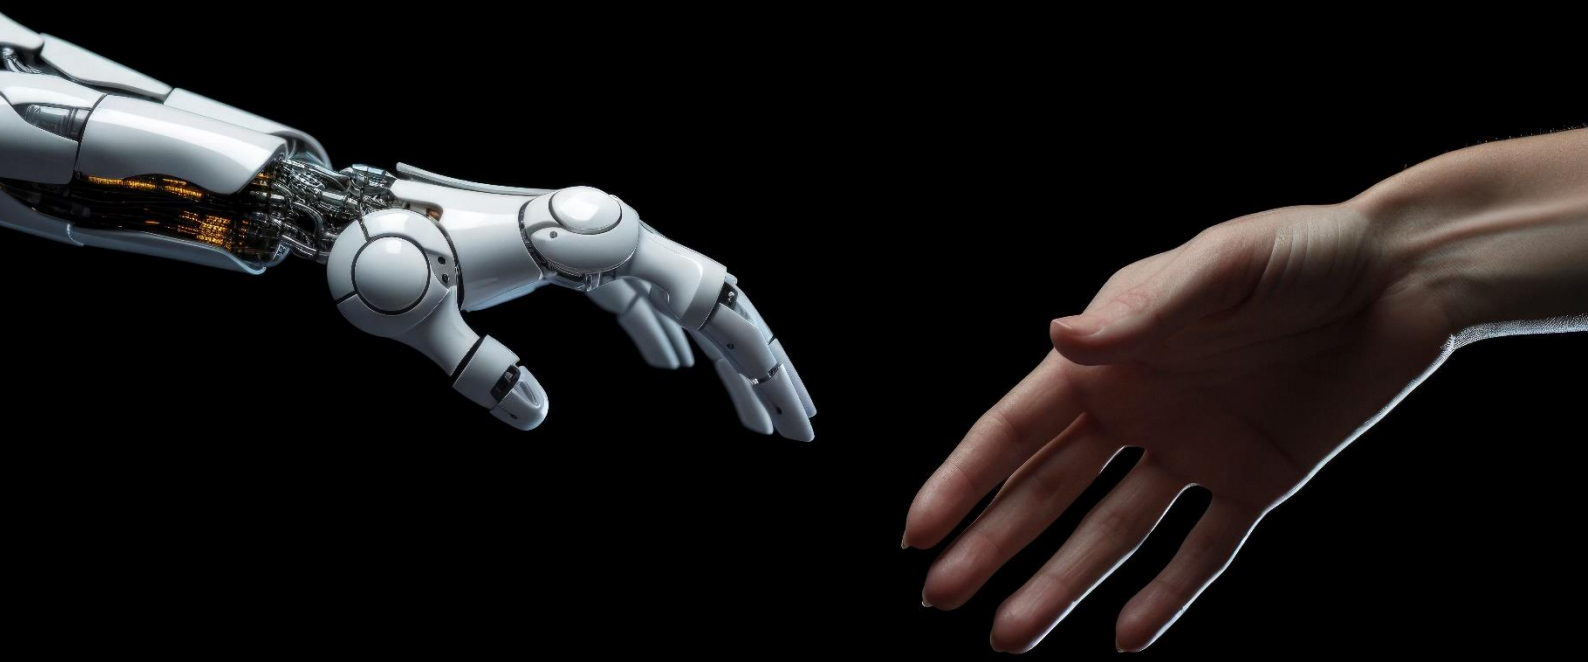
دانشگاه صنعتی اصفهان

دانشکده مهندسی برق و کامپیوتر

یادگیری ماشین

Machine Learning

پروژه اختیاری



سوال اول: در این پروژه می خواهیم داده های مربوط به مشتریان یک فروشگاه را به چند خوشه تقسیم کنیم. برای این کار مجموعه داده MAll_Customers در اختیار شما قرار گرفته است. در این مجموعه داده تعدادی ویژگی از افراد به دست آمده است. در این قسمت از پروژه شما باید مراحل زیر را اجرا و نتایج را گزارش کنید.

۱. داده ها را با کتابخانه pandas خوانده و ۸۰ درصد را برای آموزش و ۲۰ درصد را برای آزمون در نظر بگیرید. ستون CustomerID را از دیتافریم به دست آمده حذف کنید. (۵ نمره)

۳. تعداد، میانگین، انحراف معیار، کوچکترین، بزرگترین، چارک اول، چارک دوم و چارک سوم داده های هر ستون به غیر از ستون Gender را گزارش کنید. (۱۰ نمره)

۴. به کمک StandardScaler از کتابخانه sklearn.preprocessing داده ها را نرمال کنید. (به غیر از ستون جنسیت) (۵ نمره)

۵. مقادیر Female از ستون Gender را به ۱ و سایر مقادیر را به ۰ تبدیل کنید. (۵ نمره)

۶. تابعی بنویسید که ورودی های آن k و داده های یک دیتافریم باشد، و به کمک الگوریتم kmeans داده ها را به k خوشه تقسیم کند. این تابع باید موارد زیر را در خروجی مشخص کند: (استفاده از تابع آماده Kmeans هم مجاز است) (۲۰ نمره)

- مراکز خوشه ها
- خوشه مربوط به هر نمونه داده

۷. به کمک روش Elbow و silhouette برای مقادیر k بین ۲ تا ۱۰ تعداد خوشه مناسب را پیدا کرده و دلایل خود را ذکر کنید. (به دلیل جلوگیری از حساسیت به نقطه شروع باستی الگوریتم k_means را برای هرk چندین بار اجرا گردد و هر کدام که کمترین Loss را دارد، انتخاب شود.) (۲۰ نمره)

۸. با استفاده از مدل به دست آمده برای گروه بندی داده ها، خوشه ی مربوط یه هر داده را روی مجموعه داده تست پیش بینی کنید. این از مدل، مدل هر نمونه داده جدید را به نزدیکترین مرکز خوشه به آن منتسب می کند. (گروه بندی به وسیله فراخوانی تابع predict قابل انجام است.) (۳ نمره)

۹. داده های پیش بینی شده به همراه شماره ی خوشه ی پیش بینی شده را در یک فایل CSV با نام predicts.csv ذخیره کنید. (۲ نمره)

۱۰. با استفاده از روش تحلیل مؤلفه اصلی (PCA) برای کاهش بعد، ابعاد داده های آموزشی و آزمایشی را به دو ویژگی با نام های PCA1, PCA2 کاهش دهید. (۵ نمره)

۱۱. k_means را با بهترین k به دست آمده روی داده های آموزشی کاهشبعد یافته اجرا کرده و سپسخوشه مربوط به داده های آزمایشی کاهش بعد یافته را با مدل گروه بندی به دست آمده. تعیین کنید. نتایج این خوشه بندی را به صورت یک ستون مجزا به فایل predicts.csv اضافه کنید. (۱۰ نمره)

۱۲. نمودار پراکندگی[1] داده های کاهش بعد یافته را با رنگ بندی متفاوت برای هر خوشه نمایش دهید

الف) داده های آموزشی را با دایره نمایش دهید.

ب) داده های آزمایشی را با مثلث نمایش دهید.

ج) مرکز هر خوشه را با علامت "+"نمایش دهید.

د) برای نمایش بهتر داده هایی که برروی هم افتاده اند از معیار آلفا (transparency) در کشیدن نمودار استفاده کنید (۱۵ نمره)

==========

سوال دوم: در این سوال شما وظیفه دارید یک سیستم توصیه فیلم[2] را با استفاده از تکنیک های خوشه بندی بسازید. با توجه به مجموعه داده MovieLens، هدف شما این است که کاربران را بر اساس رتبه‌بندی فیلم‌هایشان خوشه‌بندی کنید و سپس فیلم‌ها را بر اساس ترجیحات کاربران دیگر در همان خوشه به یک کاربر توصیه کنید.

۱. مجموعه داده MovieLens را (شامل ratings.csv و movies.csv) لود و پیش پردازش کنید. (۵ نمره)

۲. رتبه‌بندی‌ها را عادی کنید تا مطمئن شوید امتیازها دارای میانگین ۰ و انحراف استاندارد ۱ است. (۵ نمره)

۳. خوشه بندی داده های کاربر را با استفاده از الگوریتم K-Means انجام دهید. با استفاده از روش Elbow یا Silhouette تعداد بهینه خوشه ها را تعیین کنید. (۱۵ نمره)

۴. برای یک کاربر مشخص، خوشه آنها را شناسایی کنید. N فیلم برتر را توصیه کنید که توسط سایر کاربران در همان خوشه رتبه بالایی دارند اما هنوز توسط کاربر مشخص رتبه بندی نشده اند. (۱۵ نمره)

۵. سیستم توصیه را با استفاده از معیارهایی مانند precision ، recall و F1-score ارزیابی کنید. (۱۰ نمره)

[1] Scatter plot
[2] movie recommendation

نکات تکمیلی

۱. برای انجام این تکلیف استفاده از زبان پایتون الزامی است.

۲. تکالیف را در محیط jupyter notebook پیاده سازی کنید و فایل ipynb را ارسال کنید.

۳. توضیح کدی که نوشته اید، بررسی و تحلیل نتایج آن و بیان علت نتایج و نیز مقایسه نتیجه با آنچه مورد انتظارتان بوده است، از اهمیت بالایی برخوردار است. شما می توانید گزارش پروژه را در همان محیط jupyter notebook بنویسید و نیازی به فایل pdf جداگانه نیست. هم چنین اگر برای حل سوال فرضیات خاصی مدنظر دارید حتما آن را در متن گزارش قید کنید .

۴. فرمت نامگذاری تکلیف ارسالی باید به صورت روبرو باشد: : HWX_Programming_LastName_StudentID

X شماره تکلیف، StudentID شماره دانشجویی شما است LastName نام خانوادگی شما

۵. انجام این تکلیف به صورت تک نفره است. در صورت مشاهده تقلب، نمرات هم مبدا کپی و هم مقصد آن صفر لحاظ می شود.

۶. شما می توانید تا یک هفته پس از پایان مهلت تکلیف آن را در یکتا بارگذاری کنید. در این صورت به ازای هر روز تاخیر ۵ درصد از نمره تکلیف کسر می شود. پس از اتمام این یک هفته امکان ارسال با تاخیر وجود ندارد.

۷. در صورت وجود هر گونه ابهام و یا سوال می توانید سوالات خود را در گروه تلگرام بپرسید. هم چنین می توانید برای رفع ابهامات با دستیاران آموزشی از طریق تلگرام در تماس باشید.

@Alitmz20